Thứ ngày . .

Bài 1:

Câu The cat [Mask] fish., token đúng là eats.
Model dự đoán cat 0,1, dog 0,05, eats 0.7, fish 0.15.
L = - ln P(eats) = - ln 0.7 = 0,3567

P(eats)	0.95	0.7	0.01
L	0,0513	0.3567	4,6052
so với P=0.7	giảm 7 lần		tăng 13 lần

- Vì sao cross entropy phù hợp vs MLM: MLM là phân loại trên toàn vocabulary, mỗi vị trí bị mask có đúng 1 token thật nên Log P chính là loss đúng nghĩa. Nó phạt nặng khi model tự tin mà sai (0,01 -> 4.6) và gần như ko phạt khi đúng (0.95 -> 0.05) gradient đơn giản $\partial L / \partial z_k = p_k - 1[k=y]$

Bài 2.

Tokenizer, distilbert-base-uncased (WordPiece, chữ thường). Token sequence, token ID, special token và attention mask.

Vị trí	0	1	2	4	5	6	7
token	[CLS]	the	cats	playing	-	are	[SEP]
token ID	101	1996	8870	2652	1011	2024	102
attention mask	1	1	1	1	1	1	1

- special token [CLS] (101) ở đầu - vector của nó dùng làm representation của cả câu khi classification, [SEP] (102) ở cuối đánh dấu kết câu
- attention mask: toàn 1 vì câu đứng 1 mình. Nếu cùng batch với câu dài 9 token câu này phải thêm 2 [pad] (ID 0) và mask thành [1, 1, 1, 1, 1, 1, 1, 0, 0]

HONG HA
Scanned with CamScanner

Thứ ngày . .

	số lượng	ghi chú
Words	4	The/cat/are/playing
Token	7	thêm [CLS], [SEP]
Token (bỏ special)	5	dấu "." tách khỏi playing
Subword	0	cả 4 từ đều có sẵn trong vocab

Nếu nhiều token hơn word là do special token và dấu câu tách riêng, không phải do subword. "cats" và "playing" là token nguyên. Subword chỉ xuất hiện với từ ít gặp, ví dụ: unwatchable → un ## watch ## able.

HONG HA

Scanned with CamScanner